

# 変分ベイズ法とは

正田 備也

[masada@rikkyo.ac.jp](mailto:masada@rikkyo.ac.jp)

# Contents

変分ベイズ法とは

変分ベイズ法の実例

# ベイズ的モデリングにおける変分法

- ▶ 観測データを表す確率変数を  $\mathcal{X} \equiv \{x_1, \dots, x_N\}$  とする
- ▶ データモデルのパラメータを  $\Theta$  とする
- ▶ ベイズ的なモデリングでは、 $\mathcal{X}$  だけでなく  $\Theta$  も確率変数
- ▶ 知りたいのは事後分布  $p(\Theta|\mathcal{X})$

$$p(\Theta|\mathcal{X}) = \frac{p(\mathcal{X}|\Theta)p(\Theta)}{p(\mathcal{X})} \quad (1)$$

- ▶ 変分ベイズ法は  $p(\Theta|\mathcal{X})$  を近似する分布  $q(\Theta)$  を求める
  - ▶  $q(\Theta)$  を変分法 (variational methods) で求める (後述)
  - ▶  $q(\Theta)$  を変分事後分布 (variational posterior distribution) と呼ぶ

## 前回のEMアルゴリズムでの議論のパターン

- ▶ 潜在変数  $\mathcal{Z} = \{z_1, \dots, z_N\}$  を含むモデリングを行いたい
- ▶ 確率モデルを指定することで同時分布

$p(\mathcal{X}, \mathcal{Z}) = p(\mathcal{Z})p(\mathcal{X}|\mathcal{Z}) = \prod_{i=1}^N p(z_i)p(x_i|z_i)$  が得られる

- ▶ 潜在変数  $\mathcal{Z}$  の周辺化  $\sum_{\mathcal{Z}} p(\mathcal{X}, \mathcal{Z})$  により観測データの尤度  $p(\mathcal{X})$  は得られるのだが、大抵この尤度は計算できない
- ▶ Jensen の不等式を使い、対数尤度  $\ln p(\mathcal{X})$  の下界を得る

$$\ln p(\mathcal{X}) \geq \sum_{i=1}^N \sum_{z_i} q_{i,z_i} \ln \frac{p(z_i)p(x_i|z_i)}{q_{i,z_i}}$$

- ▶ この下界を最大化することで、様々な未知量を推定する 4 / 30

# この議論のパターンを事後分布の推論へ適用

- ▶ 潜在変数  $\Theta$  を含むモデリングを行いたい
- ▶ 確率モデルを指定することで観測データと潜在変数の同時分布  $p(\mathcal{X}, \Theta) = p(\Theta)p(\mathcal{X}|\Theta) = p(\Theta) \prod_{i=1}^N p(x_i|\Theta)$  が得られる
- ▶ 潜在変数  $\Theta$  の周辺化  $\int p(\mathcal{X}, \Theta)d\Theta$  により観測データの周辺尤度  $p(\mathcal{X})$  は得られるのだが、大抵この尤度は計算できない
- ▶ Jensen の不等式を使い、対数周辺尤度  $\ln p(\mathcal{X})$  の下界を得る

$$\ln p(\mathcal{X}) \geq \int q(\Theta) \ln \frac{p(\Theta)p(\mathcal{X}|\Theta)}{q(\Theta)} d\Theta$$

- ▶ この下界を最大化することで、様々な未知量を推定する
  - ▶ この下界を ELBO(Evidence Lower BOund; 変分下限) と呼ぶ

# 変分ベイズ法 (variational Bayesian methods) とは

- ▶ Jensen の不等式を適用することで、ELBO を次のように得た

$$\ln p(\mathcal{X}) \geq \int q(\Theta) \ln \frac{p(\Theta)p(\mathcal{X}|\Theta)}{q(\Theta)} d\Theta$$

- ▶ 実は、ELBO を大きくすればするほど、 $\Theta$  が従う確率分布である  $q(\Theta)$  が、事後分布  $p(\Theta|\mathcal{X})$  に近くなっていく
- ▶ つまり、この  $q(\Theta)$  は、事後分布を近似する分布とみなせるような分布になっている
- ▶  $q(\Theta)$  は変分法 (variational method) で求められるので、変分事後分布 (variational posterior) と呼ばれる

# 「変分 (variational)」の意味

- ▶ ELBO の最大化は、 $q(\Theta)$  を変化させることでおこなう
- ▶  $q(\Theta)$  の密度関数がどんなかたちを持つかに制約を設けない
- ▶ 逆に言うと、 $q(\Theta)$  の密度関数が特定のかたちを持つと仮定した上で、その関数のパラメータだけを動かすのではない
  - ▶ パラメータについて微分することで最大化問題を解くのではなく、いわば “関数について微分する” ことで最大化問題を解いている
- ▶ とても直感的に言うと、関数のかたちを決めてそのパラメータを動かすのではなく、関数のかたち自体を動かすことで問題を解く方法を、変分法と呼ぶ (cf. 汎関数微分)

## ELBO を最大化する根拠

- ▶ Jensen の不等式の左辺から右辺を引いたものを求めてみる

$$\begin{aligned} & \ln p(\mathcal{X}) - \int q(\Theta) \ln \frac{p(\Theta|\mathcal{X})p(\mathcal{X})}{q(\Theta)} d\Theta \\ &= \ln p(\mathcal{X}) - \int q(\Theta) \ln \frac{p(\Theta|\mathcal{X})}{q(\Theta)} d\Theta - \int q(\Theta) \ln p(\mathcal{X}) d\Theta \\ &= \ln p(\mathcal{X}) - \int q(\Theta) \ln \frac{p(\Theta|\mathcal{X})}{q(\Theta)} d\Theta - \ln p(\mathcal{X}) \int q(\Theta) d\Theta \\ &= \int q(\Theta) \ln \frac{q(\Theta)}{p(\Theta|\mathcal{X})} d\Theta = D_{\text{KL}}(q(\Theta) \parallel p(\Theta|\mathcal{X})) \end{aligned} \quad (2)$$

$\therefore$  ELBO を  $\ln p(\mathcal{X})$  に近づける  $\Leftrightarrow q(\Theta)$  を  $p(\Theta|\mathcal{X})$  に近づける



# 変分事後分布に関する factorization の仮定

- ▶ モデルパラメータ  $\Theta$  について、以下のような排他的なグループ分けを行い . . .

$$\Theta = \Theta_1 \cup \dots \cup \Theta_m \quad (3)$$

- ▶ 変分事後分布が以下のように分解される、と仮定したりする

$$q(\Theta) = q(\Theta_1) \cdots q(\Theta_m) \quad (4)$$

- ▶ 「posterior factorizes」 でググってみよう
- ▶ このような仮定をすることで、ELBO の最大化問題が簡単になることがある

## 平均場近似 (mean-field approximation)

- ▶ 最も極端な場合、個々のパラメータが従う確率分布の積へ分解されると仮定することも、わりとある
- ▶  $\Theta$  が  $r$  個のパラメータ  $\theta_1, \dots, \theta_r$  からなるとすると、以下のような積へ分解されると仮定する

$$q(\Theta) = q(\theta_1) \cdots q(\theta_r) \quad (5)$$

- ▶ これを平均場近似 (mean-field approximation) と呼ぶ

# より実地的な変分ベイズ法

- ▶ 上述の factorization の仮定をおくと、それだけで、変分事後分布の密度関数のかたちが決まってしまうこともある
  - ▶ この後に示す例が、そうになっている
- ▶ しかし実際には、 $q(\Theta)$  の密度関数が特定のかたちを持つと仮定してしまった上で、その関数のパラメータを動かすことによって、ELBO を最大化することも多い
  - ▶ 例えば、 $q(\Theta)$  が多変量正規分布だと仮定して、ELBO を最大化するような平均パラメータと共分散行列パラメータを求める、など
  - ▶ 変分オートエンコーダでは、 $q(\Theta)$  が多変量正規分布だと仮定し、さらにその共分散行列が対角行列だと仮定する

# Contents

変分ベイズ法とは

変分ベイズ法の実例

# 変分ベイズ法によるデータモデリングの手順

- ▶ データモデル  $p(\mathcal{X}|\Theta)$  とモデルパラメータの事前分布  $p(\Theta; \Xi)$  を指定する
  - ▶  $\Xi$  は事前分布のパラメータ、つまり、ハイパーパラメータ
- ▶ 同時分布  $p(\mathcal{X}, \Theta; \Xi)$  を書き下す
- ▶ ELBO を書き下す
- ▶ 変分事後分布  $q(\Theta; \Psi)$  を扱いやすくするための仮定を行う
  - ▶ factorization の仮定、既知の確率分布であるという仮定、等
- ▶ その仮定を利用して、変分事後分布のパラメータ  $\Psi$  を求めるための式（多くの場合、更新式）を得る
- ▶ この式を実装して計算機で動かす

# 例：メッセージ受信数の変化点の検知

## ▶ この授業の最初に採り上げた例

▶ 参考: <http://machine-learning.hatenablog.com/entry/2017/08/19/200841>




Figure: メッセージの受信数

# モデルを指定する

- ▶  $c_n$  を  $n$  日目の受信数、 $\tau$  を受信数の変化点とする
- ▶  $\lambda_1$  は  $n < \tau$  の場合のポアソン分布のパラメータ
- ▶  $\lambda_2$  は  $n \geq \tau$  の場合のアソン分布のパラメータ

$$\tau \sim \text{Uniform}(1, N)$$

$$\lambda_1 \sim \text{Gam}(a, b)$$

$$\lambda_2 \sim \text{Gam}(a, b)$$

$$c_n \sim \text{Poi}(\lambda_1) \quad \text{for } n < \tau$$

$$c_n \sim \text{Poi}(\lambda_2) \quad \text{for } n \geq \tau$$

# 同時分布を書き下す

同時分布は、観測データを  $\mathbf{c} = \{c_1, \dots, c_N\}$  とすると

$$\begin{aligned} p(\mathbf{c}, \lambda_1, \lambda_2, \tau) &= p(\mathbf{c} | \lambda_1, \lambda_2, \tau) p(\lambda_1; a, b) p(\lambda_2; a, b) p(\tau) \\ &= p(\lambda_1; a, b) p(\lambda_2; a, b) p(\tau) \prod_{n=1}^N p(c_n | \lambda_1)^{\delta(n < \tau)} p(c_n | \lambda_2)^{\delta(n \geq \tau)} \end{aligned} \quad (6)$$

- ▶  $p(\lambda_i; a, b) \equiv \frac{b^a}{\Gamma(a)} \lambda_i^{a-1} e^{-b\lambda_i}$  for  $i = 1, 2$
- ▶  $p(\tau) \equiv \frac{1}{N}$
- ▶  $\delta(\cdot)$  は、カッコ内の命題が真ならば 1、偽ならば 0
- ▶  $p(c_n | \lambda_i) \equiv \frac{\lambda_i^{c_n} e^{-\lambda_i}}{c_n!}$  for  $i = 1, 2$



## ELBO を書き下す

$$\begin{aligned}\ln p(\mathbf{c}) &= \ln \int \sum_{\tau=1}^N p(\mathbf{c}, \lambda_1, \lambda_2, \tau) d\lambda_1 d\lambda_2 \\ &\geq \int \sum_{\tau=1}^N q(\lambda_1, \lambda_2, \tau) \ln \frac{p(\mathbf{c}, \lambda_1, \lambda_2, \tau)}{q(\lambda_1, \lambda_2, \tau)} d\lambda_1 d\lambda_2\end{aligned}\quad (7)$$

- ▶ このままではこれ以上議論を進められない
- ▶ 変分事後分布  $q(\lambda_1, \lambda_2, \tau)$  について、それを扱いやすくするような、何らかの仮定をおこなう

## 平均場近似の仮定

ここでは、変分事後分布  $q(\lambda_1, \lambda_2, \tau)$  について、  
 $q(\lambda_1, \lambda_2, \tau) = q(\lambda_1)q(\lambda_2)q(\tau)$  と分解できることを仮定する

$$\begin{aligned}\ln p(\mathbf{c}) &\geq \int \sum_{\tau=1}^N q(\lambda_1, \lambda_2, \tau) \ln \frac{p(\mathbf{c}, \lambda_1, \lambda_2, \tau)}{q(\lambda_1, \lambda_2, \tau)} d\lambda_1 d\lambda_2 \\ &= \int \sum_{\tau=1}^N q(\lambda_1)q(\lambda_2)q(\tau) \ln \frac{p(\mathbf{c}, \lambda_1, \lambda_2, \tau)}{q(\lambda_1)q(\lambda_2)q(\tau)} d\lambda_1 d\lambda_2 \quad (8)\end{aligned}$$

▶ 同時分布の式(6)を使って、ELBOをさらに詳しく書き下す

$\lambda_1, \lambda_2$  が従うガンマ事前分布のハイパーパラメータ  $a, b$  は省略する。

$$\begin{aligned}
 \ln p(\mathbf{c}) &\geq \int \sum_{\tau=1}^N q(\lambda_1)q(\lambda_2)q(\tau) \ln \frac{p(\mathbf{c}, \lambda_1, \lambda_2, \tau)}{q(\lambda_1)q(\lambda_2)q(\tau)} d\lambda_1 d\lambda_2 \\
 &= \int \sum_{\tau=1}^N q(\lambda_1)q(\lambda_2)q(\tau) \ln \frac{p(\lambda_1)p(\lambda_2)p(\tau) \prod_{n=1}^N p(c_n|\lambda_1)^{\delta(n<\tau)} p(c_n|\lambda_2)^{\delta(n\geq\tau)}}{q(\lambda_1)q(\lambda_2)q(\tau)} d\lambda_1 d\lambda_2 \\
 &= \int q(\lambda_1) \ln \frac{p(\lambda_1)}{q(\lambda_1)} d\lambda_1 + \int q(\lambda_2) \ln \frac{p(\lambda_2)}{q(\lambda_2)} d\lambda_2 + \sum_{\tau=1}^N q(\tau) \ln \frac{p(\tau)}{q(\tau)} \\
 &\quad + \sum_{\tau=1}^N \sum_{n=1}^N \delta(n < \tau) \int q(\lambda_1) \ln p(c_n|\lambda_1) d\lambda_1 + \sum_{\tau=1}^N \sum_{n=1}^N \delta(n \geq \tau) \int q(\lambda_2) \ln p(c_n|\lambda_2) d\lambda_2 \\
 &= -D_{\text{KL}}(q(\lambda_1) \parallel p(\lambda_1)) - D_{\text{KL}}(q(\lambda_2) \parallel p(\lambda_2)) - D_{\text{KL}}(q(\tau) \parallel p(\tau)) \\
 &\quad + \sum_{\tau=1}^N \sum_{n=1}^N \delta(n < \tau) \int q(\lambda_1) \ln p(c_n|\lambda_1) d\lambda_1 + \sum_{\tau=1}^N \sum_{n=1}^N \delta(n \geq \tau) \int q(\lambda_2) \ln p(c_n|\lambda_2) d\lambda_2 \quad (9)
 \end{aligned}$$

- ▶ 上記の ELBO の値を求めるコードも書いて、変分事後分布のパラメータ更新によって ELBO が徐々に大きくなっているかを、チェックする

# 変分事後分布を求める

- ▶ この例の場合、平均場近似の仮定を置くと、変分事後分布の密度関数のかたちが決まってしまう
- ▶ 具体的には、 $q(\lambda_1)$  と  $q(\lambda_2)$  と  $q(\tau)$  のうち2つを固定し、残りの1つについて、変分事後分布の事後分布に対するKL情報量  $D_{\text{KL}}(q \parallel p)$  がゼロになる条件を明らかにする
- ▶ すると、その変分事後分布の密度関数のかたちがおのずと決まってくる
  - ▶  $q(\lambda_1)$  と  $q(\lambda_2)$  の密度関数の式は、ガンマ分布のそれに一致
  - ▶  $q(\tau)$  の質量関数の式は、カテゴリカル分布のそれに一致

## $q(\lambda_1)$ の密度関数のかたちを求める (1/2)

$q(\lambda_2)$  と  $q(\tau)$  を固定し、 $D_{\text{KL}}(q(\lambda_1)q(\lambda_2)q(\tau) \parallel p(\lambda_1, \lambda_2, \tau|\mathbf{c}))$  を最小にする  $q(\lambda_1)$  を求める。

$$\begin{aligned} & D_{\text{KL}}(q(\lambda_1)q(\lambda_2)q(\tau) \parallel p(\lambda_1, \lambda_2, \tau|\mathbf{c})) \\ &= \int \sum_{\tau=1}^N q(\lambda_1)q(\lambda_2)q(\tau) \ln \frac{q(\lambda_1)q(\lambda_2)q(\tau)}{p(\lambda_1, \lambda_2, \tau|\mathbf{c})} d\lambda_1 d\lambda_2 \\ &= \int q(\lambda_1) \left\{ \ln q(\lambda_1) - \int \sum_{\tau=1}^N q(\lambda_2)q(\tau) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_2 \right\} d\lambda_1 + \text{const.} \\ &= \int q(\lambda_1) \ln \frac{q(\lambda_1)}{\exp \int \sum_{\tau=1}^N q(\lambda_2)q(\tau) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_2} d\lambda_1 + \text{const.} \end{aligned} \tag{10}$$

$\exp \int \sum_{\tau=1}^N q(\lambda_2)q(\tau) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_2$  は、 $\lambda_2$  については積分消去しており、 $\tau$  についても総和をとって消去しているので、 $\lambda_1$  の関数である。

そこで、規格化定数  $Z$  を導入することによって、 $\exp \int \sum_{\tau=1}^N q(\lambda_2)q(\tau) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_2$  を、 $\frac{1}{Z} \exp \int \sum_{\tau=1}^N q(\lambda_2)q(\tau) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_2$  という密度関数に変える。

## $q(\lambda_1)$ の密度関数のかたちを求める (2/2)

すると、

$$\begin{aligned} D_{\text{KL}}(q(\lambda_1)q(\lambda_2)q(\tau) \parallel p(\lambda_1, \lambda_2, \tau|\mathbf{c})) \\ &= \int q(\lambda_1) \ln \frac{q(\lambda_1)}{\exp \int \sum_{\tau=1}^N q(\lambda_2)q(\tau) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_2} d\lambda_1 + \text{const.} \\ &= \int q(\lambda_1) \ln \frac{q(\lambda_1)}{\frac{1}{Z} \exp \int \sum_{\tau=1}^N q(\lambda_2)q(\tau) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_2} d\lambda_1 - \int q(\lambda_1) \ln Z d\lambda_1 + \text{const.} \end{aligned}$$

となるが、 $\int q(\lambda_1) \ln Z d\lambda_1 = \ln Z \int q(\lambda_1) d\lambda_1 = \ln Z = \text{const.}$  なので

$$\begin{aligned} D_{\text{KL}}(q(\lambda_1)q(\lambda_2)q(\tau) \parallel p(\lambda_1, \lambda_2, \tau|\mathbf{c})) \\ &= D_{\text{KL}}(q(\lambda_1) \parallel \frac{1}{Z} \exp \int q(\lambda_2)q(\tau) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_2 d\tau) + \text{const.} \end{aligned} \quad (11)$$

$q(\lambda_1) = \frac{1}{Z} \exp \int \sum_{\tau=1}^N q(\lambda_2)q(\tau) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_2$  のとき、上の KL 情報量は最小。

つまり、 $\ln q(\lambda_1) = \int \sum_{\tau=1}^N q(\lambda_2)q(\tau) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_2 - \ln Z$  のとき最小。

## $q(\lambda_1)$ のパラメータを求める (1/2)

上述の KL 情報量が最小となるとき、 $q(\lambda_1)$  がどのような分布になるかを調べるため、

$\ln q(\lambda_1) = \int \sum_{\tau=1}^N q(\lambda_2)q(\tau) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c})d\lambda_2 - \ln Z$  の右辺を、計算してみる。

$$\begin{aligned} & \ln q(\lambda_1) \\ &= \int \sum_{\tau=1}^N q(\lambda_2)q(\tau) \ln \left\{ p(\lambda_1; a, b)p(\lambda_2; a, b)p(\tau) \prod_{n=1}^N p(c_n|\lambda_1)^{\delta(n<\tau)}p(c_n|\lambda_2)^{\delta(n\geq\tau)} \right\} d\lambda_2 + \text{const.} \\ &= \ln p(\lambda_1; a, b) + \int q(\lambda_2) \ln p(\lambda_2; a, b)d\lambda_2 + \sum_{\tau=1}^N q(\tau) \ln p(\tau) \\ &\quad + \sum_{n=1}^N \sum_{\tau=1}^N q(\tau)\delta(n < \tau) \ln p(c_n|\lambda_1) + \sum_{n=1}^N \int \sum_{\tau=1}^N q(\lambda_2)q(\tau)\delta(n \geq \tau) \ln p(c_n|\lambda_2)d\lambda_2 + \text{const.} \\ &= \ln p(\lambda_1; a, b) + \sum_{n=1}^N \sum_{\tau=1}^N q(\tau)\delta(n < \tau) \ln p(c_n|\lambda_1) + \text{const.} \end{aligned} \tag{12}$$

## $q(\lambda_1)$ のパラメータを求める (2/2)

ここで、事前分布  $p(\lambda_1; a, b)$  にガンマ分布の密度関数を、観測データの尤度  $p(c_n | \lambda_1)$  にポアソン分布の質量関数の式を、それぞれあてはめると、

$$\begin{aligned} \ln q(\lambda_1) &= \ln \frac{b^a}{\Gamma(a)} \lambda_1^{a-1} e^{-b\lambda_1} + \sum_{n=1}^N \left( \sum_{\tau=1}^N q(\tau) \delta(n < \tau) \right) \ln \frac{\lambda_1^{c_n} e^{-\lambda_1}}{c_n!} + const. \\ &= \left( a - 1 + \sum_{n=1}^N \left( \sum_{\tau=1}^N q(\tau) \delta(n < \tau) \right) c_n \right) \ln \lambda_1 - \left( b + \sum_{n=1}^N \left( \sum_{\tau=1}^N q(\tau) \delta(n < \tau) \right) \right) \lambda_1 + const. \end{aligned}$$

よって、 $q(\lambda_1)$  は、shape パラメータが  $a + \sum_{n=1}^N \left( \sum_{\tau=1}^N q(\tau) \delta(n < \tau) \right) c_n$  で、rate パラメータが  $b + \sum_{n=1}^N \left( \sum_{\tau=1}^N q(\tau) \delta(n < \tau) \right)$  のガンマ分布となる。

$q(\lambda_2)$  についても同様に計算すると、やはりガンマ分布であることが分かる。その shape パラメータを  $\alpha_2$ 、rate パラメータを  $\beta_2$  とすると・・・



## $q(\lambda_1; \alpha_1, \beta_1)$ と $q(\lambda_2; \alpha_2, \beta_2)$ の更新式

$$\alpha_1 \leftarrow a + \sum_{n=1}^N \left( \sum_{\tau=1}^N q(\tau) \delta(n < \tau) \right) c_n \quad (13)$$

$$\beta_1 \leftarrow b + \sum_{n=1}^N \left( \sum_{\tau=1}^N q(\tau) \delta(n < \tau) \right) \quad (14)$$

$$\alpha_2 \leftarrow a + \sum_{n=1}^N \left( \sum_{\tau=1}^N q(\tau) \delta(n \geq \tau) \right) c_n \quad (15)$$

$$\beta_2 \leftarrow b + \sum_{n=1}^N \left( \sum_{\tau=1}^N q(\tau) \delta(n \geq \tau) \right) \quad (16)$$

## $q(\tau)$ のかたちを求める

$q(\lambda_1)$  と  $q(\lambda_2)$  を固定し、 $D_{\text{KL}}(q(\lambda_1)q(\lambda_2)q(\tau) \parallel p(\lambda_1, \lambda_2, \tau|\mathbf{c}))$  を最小にする  $q(\tau)$  を求める。

$$\begin{aligned} & D_{\text{KL}}(q(\lambda_1)q(\lambda_2)q(\tau) \parallel p(\lambda_1, \lambda_2, \tau|\mathbf{c})) \\ &= \int \sum_{\tau=1}^N q(\lambda_1)q(\lambda_2)q(\tau) \ln \frac{q(\lambda_1)q(\lambda_2)q(\tau)}{p(\lambda_1, \lambda_2, \tau|\mathbf{c})} d\lambda_1 d\lambda_2 \\ &= \sum_{\tau=1}^N q(\tau) \left\{ \ln q(\tau) - \int q(\lambda_1)q(\lambda_2) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_1 d\lambda_2 \right\} + \text{const.} \\ &= \sum_{\tau=1}^N q(\tau) \ln \frac{q(\tau)}{\exp \int q(\lambda_1)q(\lambda_2) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_1 d\lambda_2} + \text{const.} \\ &= D_{\text{KL}}(q(\tau) \parallel \frac{1}{Z} \exp \int q(\lambda_1)q(\lambda_2) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_1 d\lambda_2) + \text{const.} \end{aligned} \tag{17}$$

$q(\tau) = \frac{1}{Z} \exp \int q(\lambda_1)q(\lambda_2) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_1 d\lambda_2$  のとき、上の KL 情報量は最小。

つまり、 $\ln q(\tau) = \int q(\lambda_1)q(\lambda_2) \ln p(\lambda_1, \lambda_2, \tau|\mathbf{c}) d\lambda_1 d\lambda_2 - \ln Z$  のとき最小。

上述の KL 情報量が最小となる時、 $q(\tau)$  がどういう分布になるかを調べるため、 $\ln q(\tau) = \int q(\lambda_1)q(\lambda_2) \ln p(\lambda_1, \lambda_2, \tau | \mathbf{c}) d\lambda_1 d\lambda_2 - \ln Z$  の右辺を計算してみる。

$$\begin{aligned}
 & \ln q(\tau) \\
 &= \int q(\lambda_1)q(\lambda_2) \ln \left\{ p(\lambda_1; a, b)p(\lambda_2; a, b)p(\tau) \prod_{n=1}^N p(c_n | \lambda_1)^{\delta(n < \tau)} p(c_n | \lambda_2)^{\delta(n \geq \tau)} \right\} d\lambda_1 d\lambda_2 - \ln Z \\
 &= \int q(\lambda_1) \ln p(\lambda_1; a, b) d\lambda_1 + \int q(\lambda_2) \ln p(\lambda_2; a, b) d\lambda_2 \\
 &\quad + \sum_{n=1}^N \delta(n < \tau) \int q(\lambda_1) \ln p(c_n | \lambda_1) d\lambda_1 + \sum_{n=1}^N \delta(n \geq \tau) \int q(\lambda_2) \ln p(c_n | \lambda_2) d\lambda_2 + \text{const.}
 \end{aligned}$$

この式は、異なる  $\tau$  ごとに単に別々の値をとる。よって、 $q(\tau)$  はカテゴリカル分布であり、

$$q(\tau) \propto \exp \left[ \sum_{n=1}^N \delta(n < \tau) \int q(\lambda_1) \ln p(c_n | \lambda_1) d\lambda_1 + \sum_{n=1}^N \delta(n \geq \tau) \int q(\lambda_2) \ln p(c_n | \lambda_2) d\lambda_2 \right]$$

となる。ただし、 $\sum_{\tau=1}^N q(\tau) = 1$  を満たす。

$q(\lambda_1)$  と  $q(\lambda_2)$  がガンマ分布であることを利用して、さらに式変形する。

$$\begin{aligned}
\sum_{n=1}^N \delta(n < \tau) \int q(\lambda_1; \alpha_1, \beta_1) \ln p(c_n | \lambda_1) d\lambda_1 &= \sum_{n=1}^N \delta(n < \tau) \int q(\lambda_1; \alpha_1, \beta_1) \ln \frac{\lambda_1^{c_n} e^{-\lambda_1}}{c_n!} d\lambda_1 \\
&= \{\psi(\alpha_1) - \ln(\beta_1)\} \sum_{n=1}^N \delta(n < \tau) c_n - \frac{\alpha_1}{\beta_1} \sum_{n=1}^N \delta(n < \tau) - \sum_{n=1}^N \delta(n < \tau) \ln c_n! \quad (18)
\end{aligned}$$

$$\begin{aligned}
\sum_{n=1}^N \delta(n \geq \tau) \int q(\lambda_2) \ln p(c_n | \lambda_2) d\lambda_2 &= \dots \\
&= \{\psi(\alpha_2) - \ln(\beta_2)\} \sum_{n=1}^N \delta(n \geq \tau) c_n - \frac{\alpha_2}{\beta_2} \sum_{n=1}^N \delta(n \geq \tau) - \sum_{n=1}^N \delta(n \geq \tau) \ln c_n! \quad (19)
\end{aligned}$$

$$\begin{aligned}
\therefore q(\tau) \propto \exp \left[ \{\psi(\alpha_1) - \ln(\beta_1)\} \sum_{n=1}^{\tau-1} c_n + \{\psi(\alpha_2) - \ln(\beta_2)\} \sum_{n=\tau}^N c_n - \frac{(\tau-1)\alpha_1}{\beta_1} - \frac{(N-\tau+1)\alpha_2}{\beta_2} \right] \quad (20)
\end{aligned}$$

# まとめ

- ▶ メッセージ受信数の変化点を検知するため、ベイズ的なモデルを立てた
- ▶ 事後分布を近似するために、変分ベイズ法を使った
- ▶ その際、変分事後分布  $q(\lambda_1, \lambda_2, \tau)$  について、  
 $q(\lambda_1, \lambda_2, \tau) = q(\lambda_1)q(\lambda_2)q(\tau)$  と分解できることを仮定した
- ▶ このように仮定すると、 $q(\lambda_1)$  と  $q(\lambda_2)$  はガンマ分布となり、 $q(\tau)$  はカテゴリカル分布となった

# 今日の課題

- ▶ メッセージ受信数の変化点検知の例を考える。
- ▶  $\lambda_1$  の値が従う変分事後分布  $q(\lambda_1)$  は、ガンマ分布であることが分かった。
- ▶ そこで、 $q(\lambda_1)$  の shape パラメータを  $\alpha_1$  とし、rate パラメータを  $\beta_1$  とする。
- ▶ このとき、 $\int q(\lambda_1; \alpha_1, \beta_1) \ln p(\lambda_1; a, b) d\lambda_1$  を計算せよ。
  - ▶ これは ELBO の算出に必要な計算。
  - ▶ ヒント 1 :  $q(\lambda_1)$  のパラメータ  $\alpha_1$  と  $\beta_1$  を使って答えを表す。
  - ▶ ヒント 2 :  $p(\lambda_1; a, b)$  がガンマ分布で、shape パラメータは  $a$ 、rate パラメータは  $b$  であることも当然使う。